

Gustavo Arreola Almaguer

2074164

Producto Integrador de Aprendizaje

Minería de Datos

Hallazgos obtenidos durante las practicas

En este reporte se abarcaran aquellos hallazgos que fueron encontrados durante la realización de las practicas anteriores junto con las pruebas visuales de los hallazgos las cuales se realizaron con el código presente en la carpeta de este proyecto.

Hallazgos de la practica 1

1. Como primer hallazgo esta la conversión de la variable “date” de tipo str a tipo date para poder trabajar con estos datos más fácilmente.
2. Como segundo hallazgo esta el renombramiento de columnas para eliminar caracteres especiales y espacios dándoles sus reemplazos correspondientes para que no se dificulte trabajar con ellos.

```
Hallazgos Practica 1
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 18 columns):
#   Column              Non-Null Count  Dtype  
---  -
0   date                8760 non-null  object 
1   rented_bike_count    8760 non-null  int64  
2   hour                8760 non-null  int64  
3   temperature          8760 non-null  float64 
4   humidity             8760 non-null  int64  
5   wind_speed           8760 non-null  float64 
6   visibility            8760 non-null  int64  
7   dew_point_temperature 8760 non-null  float64 
8   solar_radiation      8760 non-null  float64 
9   rainfall             8760 non-null  float64 
10  snowfall             8760 non-null  float64 
11  holiday              8760 non-null  int64  
12  functioning_day       8760 non-null  int64  
13  seasons_Autumn        8760 non-null  bool    
14  seasons_Spring        8760 non-null  bool    
15  seasons_Summer        8760 non-null  bool    
16  seasons_Winter        8760 non-null  bool    
17  cluster               8760 non-null  int64  
dtypes: bool(4), float64(6), int64(7), object(1)
memory usage: 992.5+ KB
```

Hallazgos Practica 2

1. Como primer hallazgo esta que descubrimos que existe una alta variabilidad en la demanda por medio de datos como la media, mediana y desviación estandar, los cuales tienen valores de 704.6 bicicletas, 504.5 y 645, respectivamente.
2. Conocimos a través de esta practica la distribución de las 4 estaciones del año las cuales tienen una diferencia muy pequeña en sus porcentajes de rentas lo cual las vuelve prácticamente uniformes y por ende revela que el factor de temporada no es determinante en la demanda, contrario a lo que se pensaba en un inicio.
3. Como tercer hallazgo destacable esta el descubrimiento de cuales son los periodos de horas del día que generan más rentas y menos rentas siendo estos los horarios de 4 pm a 9 pm y de 1 am a 6 am respectivamente.

```
Hallazgos Practica 2
rented_bike_count
count      8760.000000
mean       704.602055
std        644.997468
min         0.000000
25%        191.000000
50%        504.500000
75%       1065.250000
max       3556.000000
```

```
seasons_Spring  25.205479
seasons_Summer  25.205479
seasons_Autumn  24.931507
seasons_Winter  24.657534
```


```
hour
18    548568
19    436229
17    415556
20    390172
21    376479
8     370731
16    339677
```

```
1    155557
2    110095
6    104961
3     74216
5     50765
4     48396
```


Hallazgos Practica 3

1. En base al gráfico de pastel realizado para tener una representación visual de la distribución de las estaciones podemos confirmar que el hallazgo escrito en la diapositiva anterior es correcto, es decir, el factor de la temporada del año no es determinante para la cantidad de rentas.
2. La gráfica de tendencia por hora realizado en esta misma practica sirve para confirmar de una forma visual que los dos periodos antes mencionados son aquellos en los que tenemos la mayor cantidad y menor cantidad de rentas respectivamente.

Distribución de rentas por Estaciones



Tendencia por Hora



Hallazgos Practica 4

1. Como primer hallazgo destacable de la practica tenemos el hecho de que pudimos averiguar que tan grandes son las diferencias entre los grupos horarios la cual podemos afirmar que es considerablemente grande debido a que el valor del estadístico de prueba es 1332.05, lo cual era lo que esperábamos de esta prueba.
2. Usando el análisis Post-hoc de Dunn pudimos realizar comparaciones entre los 4 grupos, siendo una comparación para cada uno de los 6 pares de combinaciones posibles y en base a estos resultados podemos destacar las siguientes diferencias:
 - Tarde vs Noche/Madrugada: es la diferencia más grande, contando con un valor p de 1.498×10^{-259} confirmando que la tarde es el periodo de mayor demanda y la noche el periodo de menor demanda, coincidiendo con lo que se esperaba.
 - Mañana vs Mediodía: es una diferencia significativa pero la más pequeña de las comparaciones contando con un valor p de 4.026×10^{-21} .



```
Hallazgos Practica 4
Prueba para partes del día:
Estadístico de Prueba: 1332.0465
Valor-P: 1.6380e-288
```

```
Resultados del Post-hoc (Dunn):
```

	Mañana	Mediodía	Noche/Madrugada	Tarde
Mañana	1.000000e+00	4.026172e-21	6.963288e-39	7.378042e-82
Mediodía	4.026172e-21	1.000000e+00	3.946862e-131	3.146731e-26
Noche/Madrugada	6.963288e-39	3.946862e-131	1.000000e+00	1.498643e-259
Tarde	7.378042e-82	3.146731e-26	1.498643e-259	1.000000e+00



Hallazgos Practica 5

1. En esta ocasión los hallazgos fueron obtenidos en base a la aplicación de la técnica de regresión lineal simple, obteniendo un puntaje de R^2 de 0.29, es decir, que el modelo explica únicamente un 29 de la variabilidad en la demanda de bicicletas, si bien este es un valor bajo, es bastante esperable considerando que la cantidad de variables existentes es de 10 y en este caso solo se trabajo con la variable de temperatura provocando que el predictor limite la capacidad del modelo.
2. Como segundo hallazgo tenemos la interpretación del modelo el cual solo dio un puntaje de R^2 de 0.29 lo que quiere decir que se aleja mucho de ser un modelo perfecto y para que lo sea, los puntos debieron formar una diagonal exacta pero como la nube que se formo es demasiado horizontal, lo cual lleva a la conclusión de que el modelo sobreestima valores altos y subestima a los valores bajos.




Hallazgos Practica 6

1. Aquí se aplicó la técnica de KNN después de haber usado el método del codo para determinar el valor óptimo de K el cual es de $K = 5$ con una precisión de 78.54% el cual era el valor que al principio se estimaba que sería el de mayor precisión.
2. En la parte de la visualización de KNN donde usamos 3 categorías para clasificar por baja demanda, media demanda y alta demanda, lo verdaderamente importante aquí es la presencia de mezclas entre categorías en la zona central de la gráfica, dando un resultado que no esperábamos siendo este que la transición entre niveles de demanda es gradual y no existen límites perfectamente definidos.




Hallazgos Practica 7

1. A diferencia de la practica anterior donde solo se uso el método del codo para determinar el valor de K en esta practica se uso también la técnica conocida como silhouette score para tomar una decisión más precisa y correcta lo que dio como resultado que se dieran dos valores óptimos diferentes siendo estos $K = 3$ por parte del método del codo y $K = 4$ por parte de silhouette score pero en este caso se opto por usar un valor de $K = 4$ con el fin de reducir la ambigüedad entre observaciones y así dar una segmentación más concreta de las condiciones climáticas y de demanda.
2. Gracias a la visualización de clusters podemos ver varias combinaciones las cuales son baja demanda y temperaturas bajas, demanda moderada y clima nubloso o fresco, flujo constante de usuarios y clima agradable y por ultimo, alta demanda y mayor radiación solar. Estos siendo representados por los colores morado, azul, verde y amarillo respectivamente.




```
Hallazgos Practica 7
Para k=2, el Silhouette Score es: 0.3480
Para k=3, el Silhouette Score es: 0.3264
Para k=4, el Silhouette Score es: 0.3596
Para k=5, el Silhouette Score es: 0.3108
Para k=6, el Silhouette Score es: 0.3068
Para k=7, el Silhouette Score es: 0.2858
Para k=8, el Silhouette Score es: 0.2840
Para k=9, el Silhouette Score es: 0.2812
Para k=10, el Silhouette Score es: 0.2838
```



Hallazgos Practica 8

1. Como primer hallazgo de esta practica tenemos que ahora podemos aplicar prácticas directas en base a la predicción realizada la cual dio un valor de 935.13 bicicletas. Estas practicas abarcan las áreas de logística, costos operativos y planificación urbana.
2. En base a la gráfica de predicción vs real nos sirve para llegar a dos conclusiones importantes, si hablamos de valores exactos el modelo es poco confiable, debido a que las líneas siguen patrones considerablemente diferentes y rara vez se cruzan entre si, pero si hablamos de la tendencia general el modelo si es confiable ya que las líneas siguen patrones similares de subida y bajada lo que significa que puede indicar correctamente si la demanda subirá o disminuirá, aunque no con el numero exacto.

Hallazgos Practica 8
Predicción para la siguiente hora: 935.13 bicicletas



Hallazgos Practica 9

1. Aunque es la técnica más simple de todas las practicadas, sirve como una validación visual rápida de la importancia relativa de las variables, siendo coherente con los resultados obtenidos en los modelos más complejos de prácticas anteriores.

