Gustavo Arreola Almaguer
2074164
Practica 1
Minería de Datos

Limpieza de Datos

La limpieza se llevo a cabo con el propósito de eliminar o cambiar aquellos datos que podrían dar una problemática en un futuro ya sea por su tipo de variable, también puede ser que el valor que tiene sea erróneo por ejemplo un valor negativo para las cantidad de rentas por horas de bicicletas como se muestra en el dataset o por que directamente no hay nada en esa casilla con lo que se pueda trabajar.

En esta parte del proceso no hubo valores nulos que llenar únicamente hubo valores como por ejemplo las fechas que no tenían el tipo de variable adecuado para aplicar las técnicas que se verán en las siguientes diapositivas y tuvieron que ser cambiados durante esta parte de la practica al igual que otras de las columnas contenidas en el dataset.

Otro cambio que se tuvo que hacer para evitar problemas a futuro fue cambiar el nombre de las columnas para evitar el uso de caracteres como “°” y evitar que la columnas tengan nombre con espacios usando “_” para que se siga entendiendo el contenido de la columna.

Antes de la limpieza

```
(8760, 14)

Cantidad de variables flotantes, enteras y categoricas antes de la limpieza
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 14 columns):
 #   Column                     Non-Null Count  Dtype
---  ------                     --------------  -----
 0   Date                       8760 non-null   object
 1   Rented Bike Count          8760 non-null   int64
 2   Hour                       8760 non-null   int64
 3   Temperature(°C)            8760 non-null   float64
 4   Humidity(%)                8760 non-null   int64
 5   Wind speed (m/s)           8760 non-null   float64
 6   Visibility (10m)           8760 non-null   int64
 7   Dew point temperature(°C)  8760 non-null   float64
 8   Solar Radiation (MJ/m2)    8760 non-null   float64
 9   Rainfall(mm)               8760 non-null   float64
 10  Snowfall (cm)              8760 non-null   float64
 11  Seasons                    8760 non-null   object
 12  Holiday                    8760 non-null   object
 13  Functioning Day            8760 non-null   object
dtypes: float64(6), int64(4), object(4)
```

En esta primer captura se muestra la cantidad de filas, columnas y la cantidad de variables de cada tipo contenidas en el dataset al igual que sus nombres antes de realizar los cambios mencionados en la diapositiva anterior.

Después de la limpieza

Aquí podemos notar varios cambios con respecto a la información vista en la diapositiva anterior, lo primero es que la columna “date” ahora maneja datos tipo date y no texto como se veía anteriormente otro cambio que se puede ver esta en los nombres de las columnas que fueron cambiados para facilitar su uso a futuro.

Otra cosa que se puede notar es que efectivamente no hubo necesidad de añadir datos en casillas nulas debido a que no hubo casillas que rellenar en todo el dataset

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8760 entries, 0 to 8759
Data columns (total 14 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   date                   8760 non-null   datetime64[ns]
 1   rented_bike_count      8760 non-null   int64
 2   hour                   8760 non-null   int64
 3   temperature            8760 non-null   float64
 4   humidity               8760 non-null   int64
 5   wind_speed             8760 non-null   float64
 6   visibility             8760 non-null   int64
 7   dew_point_temperature  8760 non-null   float64
 8   solar_radiation        8760 non-null   float64
 9   rainfall               8760 non-null   float64
 10  snowfall               8760 non-null   float64
 11  seasons                8760 non-null   object
 12  holiday                8760 non-null   object
 13  functioning_day        8760 non-null   object
dtypes: datetime64[ns](1), float64(6), int64(4), object(3)
```

Clustering

Esta es una de las técnicas que quise implementar después de realizar la limpieza del dataset con el propósito de descubrir y comparar grupos por medio del algoritmo K-Means y el método del codo o elbow method para elegir el numero de grupos.

Con esta gráfica se pueden notar varias cosas la primera es que en el eje vertical hay números bastante grandes este pasa por la naturaleza de los datos que manejamos y por como K-Means realiza los cálculos correspondientes

El dataset maneja mas de 8000 filas y la inercia es una suma acumulada de todas esas distancias dicho de otra forma mientras más datos haya mayor será el numero total.

El valor que tiene la inercia también depende de la cantidad de clusters, por ejemplo si la cantidad de clusters es 1 la inercia tendrá un valor aproximado de 140000, pero como se puede ver cada que la cantidad de clusters aumenta se disminuye el valor que tiene la inercia al igual que la diferencia que hay entre las inercias con x clusters y y clusters, por ejemplo cuando hay 1 cluster el valor de la inercia es aproximado a 140000 y cuando hay 2 clusters este valor baja a aproximadamente 115000 ahora si usamos 2 y 3 como la cantidad de clusters respectivamente podemos notar que pasa de aproximadamente 115000 a aproximadamente 100000 provocando que la diferencia pase de 25000 a 15000.

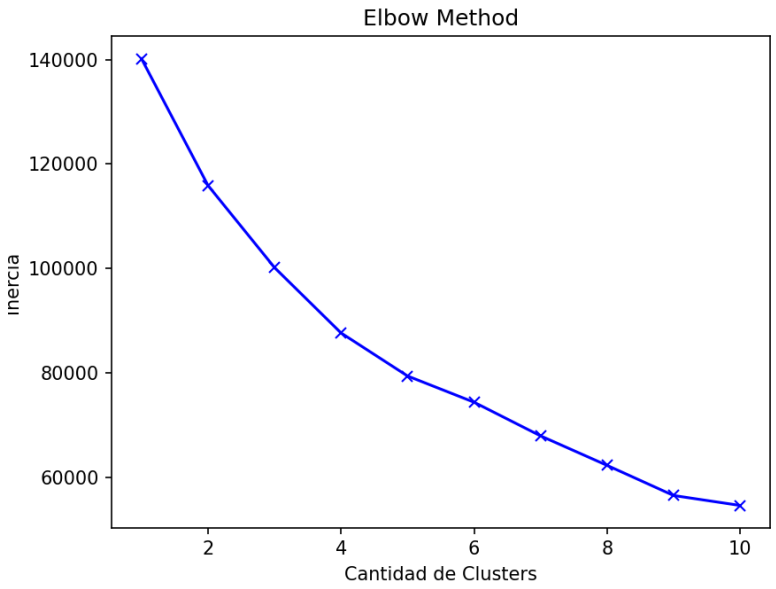

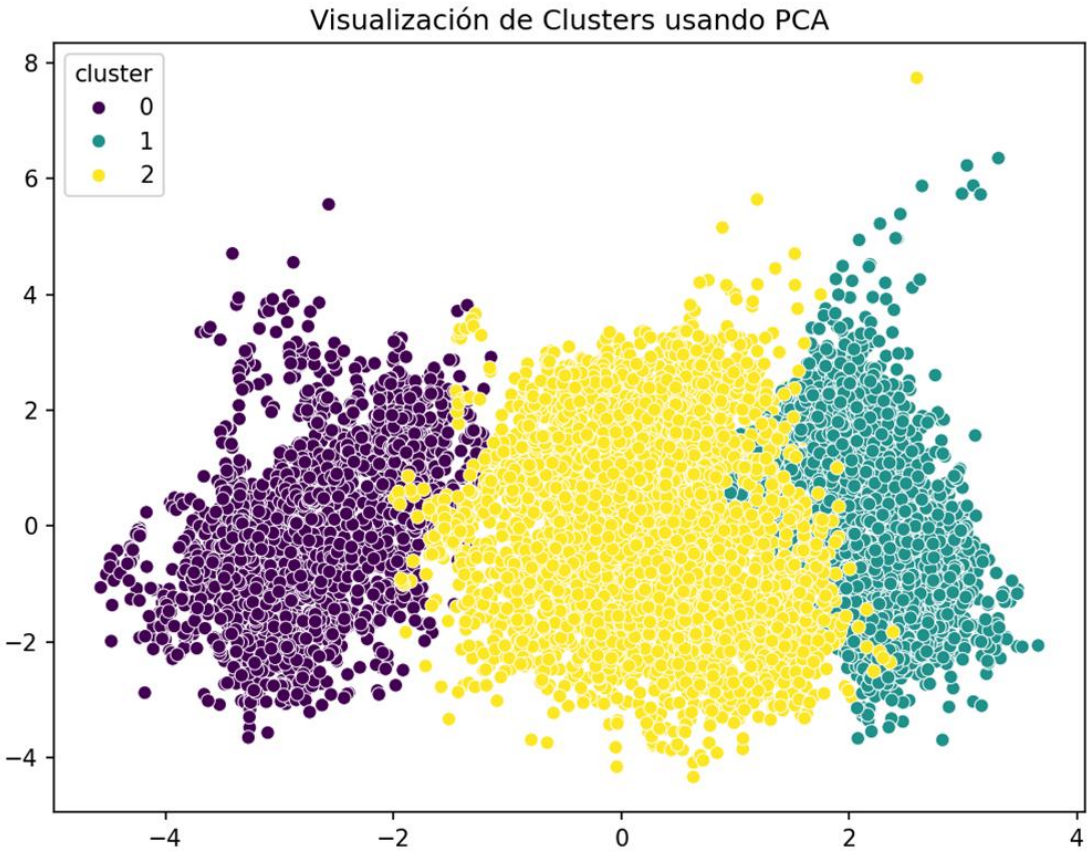

Para realizar la visualización de clusters decidimos usar el método PCA debido a la cantidad de columnas que contiene el dataset.

PCA comprime todas las variables en solo dos que en este caso vendrían a ser el eje x y el eje y que conservan la mayor información posible.

Clusters

Cluster 0: Este cluster representa un perfil de comportamiento especifico. Posiblemente sean los datos con menor demanda.

Cluster 1: Este grupo podría representar los días de demanda pico o condiciones climáticas ideales.

Cluster 2: Este grupo representa la normalidad es decir el comportamiento promedio del sistema de bicicletas.

Algo que podemos notar es que los puntos están un poco mezclados esto quiere decir que la transición entre un perfil es gradual.

Predicción

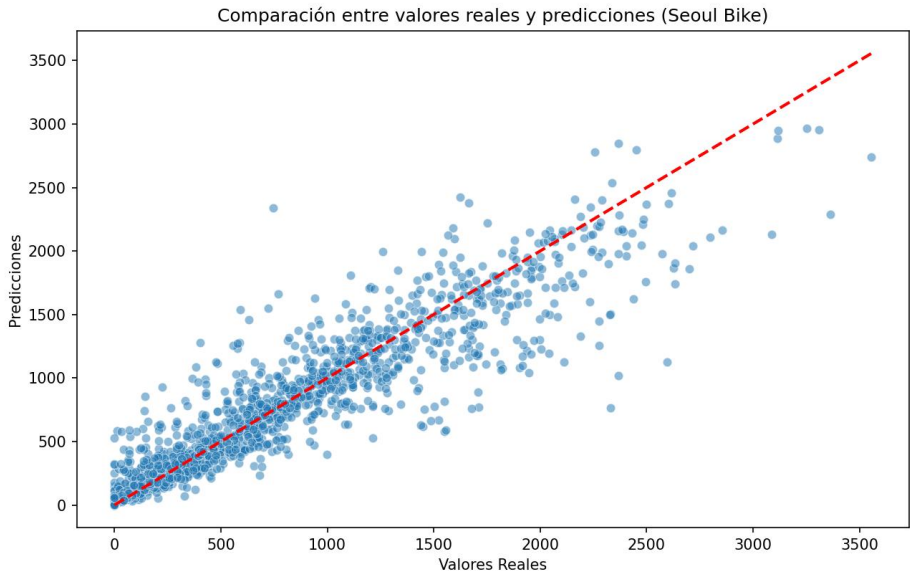

Utilice esta segunda técnica ya que considero que puede funcionar muy bien en este dataset en especifico ya que el objetivo es el de predecir la variable continua rented_bike_count, utilizando un algoritmo de random_forest_regressor aquí se realizo un entrenamiento del 80% de los datos y 20% de los datos se usaran para pruebas, a partir del modelo se realizaron las predicciones y después la evaluación correspondiente para obtener MAE y R2 que son las métricas que se utilizaron para evaluar el error.

```
--- Evaluación del Modelo ---
Error Absoluto Medio (MAE): 144.00 bicicletas
Coeficiente de Determinación (R2): 0.86
```

Aquí podemos ver la evaluación del modelo donde se nos presenta un Error Absoluto Medio (MAE) de 144 bicicletas, esto quiere decir que las predicciones suelen estar a 144 bicicletas de la realidad ya sea más o menos.

Por ultimo podemos ver también que el coeficiente de determinación es de 0.86 lo cual es considerado como un buen resultado para este dataset. Ya que ayudaría a que la empresa tome decisiones de negocio realistas