Gustavo Arreola Almaguer
2074164
Practica 2
Minería de Datos

Estadística Descriptiva

En el presente reporte hablara y mostrada acerca de la estadística descriptiva del dataset previamente seleccionado y limpiado con el propósito de mostrar de una manera más organizada el conjunto de datos y así hacer mas sencilla la comprensión de la información al momento de presentarla.

En esta ocasión se busco mostrar las medidas de tendencia central, las medidas de variabilidad o dispersión, la correlación y como añadido se incluyeron dos estadísticas de forma siendo estas la asimetría y la curtosis.

En las siguientes diapositivas se mostraran varias de estas medidas para todas las columnas presentes en el dataset algunas de estas fueron descartadas debido a que su aporte no se le considero lo suficientemente requerido.

	date	rented_bike_count	hour \
count	8760	8760.000000	8760.000000
mean	2018-05-31 23:59:59.999999744	704.602055	11.500000
min	2017-12-01 00:00:00	0.000000	0.000000
25%	2018-03-02 00:00:00	191.000000	5.750000
50%	2018-06-01 00:00:00	504.500000	11.500000
75%	2018-08-31 00:00:00	1065.250000	17.250000
max	2018-11-30 00:00:00	3556.000000	23.000000
std	NaN	644.997468	6.922582

	temperature	humidity	wind_speed	visibility \
count	8760.000000	8760.000000	8760.000000	8760.000000
mean	12.882922	58.226256	1.724909	1436.825799
min	-17.800000	0.000000	0.000000	27.000000
25%	3.500000	42.000000	0.900000	940.000000
50%	13.700000	57.000000	1.500000	1698.000000
75%	22.500000	74.000000	2.300000	2000.000000
max	39.400000	98.000000	7.400000	2000.000000
std	11.944825	20.362413	1.036300	608.298712

	dew_point_temperature	solar_radiation	rainfall	snowfall \
count	8760.000000	8760.000000	8760.000000	8760.000000
mean	4.073813	0.569111	0.148687	0.075068
min	-30.600000	0.000000	0.000000	0.000000
25%	-4.700000	0.000000	0.000000	0.000000
50%	5.100000	0.010000	0.000000	0.000000
75%	14.800000	0.930000	0.000000	0.000000
max	27.200000	3.520000	35.000000	8.800000
std	13.060369	0.868746	1.128193	0.436746

	holiday	functioning_day	cluster	month
count	8760.000000	8760.000000	8760.000000	8760.000000
mean	0.049315	0.966324	1.252968	6.526027
min	0.000000	0.000000	0.000000	1.000000
25%	0.000000	1.000000	1.000000	4.000000
50%	0.000000	1.000000	2.000000	7.000000
75%	0.000000	1.000000	2.000000	10.000000
max	1.000000	1.000000	2.000000	12.000000
std	0.216537	0.180404	0.827061	3.448048

En esta primer captura podemos encontrar tanto medidas de tendencia central como medidas de dispersión de la mayoría de las columnas del dataset ya que se encuentran medidas como la media, la mediana, la desviación estándar, el punto máximo y mínimo los cuales nos sirven para calcular y como se puede ver se descarto únicamente la columna de seasons la cual se tratara en diapositivas posteriores

```
seasons_Spring    25.205479
seasons_Summer    25.205479
seasons_Autumn    24.931507
seasons_Winter    24.657534
```

Aquí se pueden ver los porcentajes de rentas anuales durante cada estación del año del que se recopilo la información donde podemos notar que realmente no hay una diferencia muy grande entre el porcentaje de rentas entre cada estación siendo este de apenas unas decimas.

```
18    548568
19    436229
17    415556
20    390172
21    376479
8     370731
16    339677
22    336821
15    302653
14    276971
13    267635
12    255296
23    244961
9     235784
7     221192
11    219311
0     197633
10    192655
1     155557
2     110095
6     104961
3      74216
5      50765
4      48396
Name: rented_bike_count, dtype: int64
```

A continuación se pueden ver los totales de bicicletas rentadas en cada hora acumulando las rentas de todos los días del año, esto nos sirve para notar en que horas nos fue mejor durante y además si en un dado caso el negocio quisiera reducir sus horas de trabajo por ejemplo pasar de 24 horas a 18 horas laborales puede decidir que horario seria más conveniente cerrar y en que horario seria mejor seguir trabajando en este caso lo mejor seria cerrar de 1 am a 6 am que es cuando hay menor cantidad de rentas.

	rented_bike_count	hour	temperature	humidity
rented_bike_count	1.000000	4.102573e-01	0.538558	-0.199780
hour	0.410257	1.000000e+00	0.124114	-0.241644
temperature	0.538558	1.241145e-01	1.000000	0.159371
humidity	-0.199780	-2.416438e-01	0.159371	1.000000
wind_speed	0.121108	2.851967e-01	-0.036252	-0.336683
visibility	0.199280	9.875348e-02	0.034794	-0.543090
dew_point_temperature	0.379788	3.054372e-03	0.912798	0.536894
solar_radiation	0.261837	1.451309e-01	0.353505	-0.461919
rainfall	-0.123074	8.714642e-03	0.050282	0.236397
snowfall	-0.141804	-2.151645e-02	-0.218405	0.108183
holiday	-0.072338	-1.391486e-16	-0.055931	-0.050278
functioning_day	0.203943	5.439377e-03	-0.050170	-0.020800
seasons_Autumn	0.102753	1.991407e-15	0.059728	0.028367
seasons_Spring	0.022888	-1.159917e-15	0.007960	0.015694
seasons_Summer	0.296549	8.578102e-16	0.665846	0.192595
seasons_Winter	-0.424925	-1.697335e-15	-0.738720	-0.238295
cluster	0.289096	1.304937e-15	0.422480	0.143906

En esta diapositiva y en la siguiente podremos conocer las correlaciones que existen entre cada una de las columnas podemos encontrar en el dataset.

Esto tiene como propósito el facilitarnos la comprensión de como se relacionan unas columnas con otras además de sernos de utilidad al momento de querer predecir resultados futuros

	wind_speed	visibility	dew_point_temperature	\
rented_bike_count	0.121108	0.199280	0.379788	
hour	0.285197	0.098753	0.003054	
temperature	-0.036252	0.034794	0.912798	
humidity	-0.336683	-0.543090	0.536894	
wind_speed	1.000000	0.171507	-0.176486	
visibility	0.171507	1.000000	-0.176630	
dew_point_temperature	-0.176486	-0.176630	1.000000	
solar_radiation	0.332274	0.149738	0.094381	
rainfall	-0.019674	-0.167629	0.125597	
snowfall	-0.003554	-0.121695	-0.150887	
holiday	0.023017	0.031773	-0.066759	
functioning_day	0.005037	-0.026000	-0.052837	
seasons_Autumn	-0.128009	0.117413	0.062878	
seasons_Spring	0.083855	-0.187498	0.002056	
seasons_Summer	-0.064698	0.061958	0.652378	
seasons_Winter	0.109186	0.008616	-0.722366	
cluster	-0.080882	-0.039680	0.411119	

	solar_radiation	rainfall	snowfall	holiday	\
rented_bike_count	0.261837	-0.123074	-0.141804	-7.233757e-02	
hour	0.145131	0.008715	-0.021516	-1.391486e-16	
temperature	0.353505	0.050282	-0.218405	-5.593084e-02	
humidity	-0.461919	0.236397	0.108183	-5.027765e-02	
wind_speed	0.332274	-0.019674	-0.003554	2.301677e-02	
visibility	0.149738	-0.167629	-0.121695	3.177281e-02	
dew_point_temperature	0.094381	0.125597	-0.150887	-6.675910e-02	
solar_radiation	1.000000	-0.074290	-0.072301	-5.077255e-03	
rainfall	-0.074290	1.000000	0.008500	-1.426911e-02	
snowfall	-0.072301	0.008500	1.000000	-1.259072e-02	
holiday	-0.005077	-0.014269	-0.012591	1.000000e+00	
functioning_day	-0.007665	0.002055	0.032089	-2.762445e-02	
seasons_Autumn	-0.031374	-0.013247	-0.024742	1.498458e-02	
seasons_Spring	0.079974	0.017595	-0.099785	-4.479057e-02	
seasons_Summer	0.128402	0.053928	-0.099785	-7.393239e-02	
seasons_Winter	-0.178420	-0.058755	0.225875	1.045574e-01	
cluster	0.119161	0.030553	-0.214784	-6.966654e-02	

	functioning_day	seasons_Autumn	seasons_Spring	\
rented_bike_count	0.203943	1.027530e-01	2.288822e-02	
hour	0.005439	1.991407e-15	-1.159917e-15	
temperature	-0.050170	5.972825e-02	7.959684e-03	
humidity	-0.020800	2.836650e-02	1.569416e-02	
wind_speed	0.005037	-1.280093e-01	8.385451e-02	
visibility	-0.026000	1.174133e-01	-1.874983e-01	
dew_point_temperature	-0.052837	6.287829e-02	2.055888e-03	
solar_radiation	-0.007665	-3.137428e-02	7.997416e-02	
rainfall	0.002055	-1.324655e-02	1.759519e-02	
snowfall	0.032089	-2.474218e-02	-9.978516e-02	
holiday	-0.027624	1.498458e-02	-4.479057e-02	
functioning_day	1.000000	-2.537183e-01	3.841275e-02	
seasons_Autumn	-0.253718	1.000000e+00	-3.345477e-01	
seasons_Spring	0.038413	-3.345477e-01	1.000000e+00	
seasons_Summer	0.108370	-3.345477e-01	-3.369963e-01	
seasons_Winter	0.106795	-3.296859e-01	-3.320989e-01	
cluster	-0.168626	5.154560e-01	5.243712e-01	

	seasons_Summer	seasons_Winter	cluster
rented_bike_count	2.965494e-01	-4.249251e-01	2.890964e-01
hour	8.578102e-16	-1.697335e-15	1.304937e-15
temperature	6.658462e-01	-7.387196e-01	4.224800e-01
humidity	1.925949e-01	-2.382952e-01	1.439063e-01
wind_speed	-6.469790e-02	1.091865e-01	-8.088208e-02
visibility	6.195792e-02	8.616224e-03	-3.968042e-02
dew_point_temperature	6.523778e-01	-7.223664e-01	4.111191e-01
solar_radiation	1.284017e-01	-1.784202e-01	1.191615e-01
rainfall	5.392817e-02	-5.875456e-02	3.055335e-02
snowfall	-9.978516e-02	2.258745e-01	-2.147836e-01
holiday	-7.393239e-02	1.045574e-01	-6.966654e-02
functioning_day	1.083703e-01	1.067954e-01	-1.686257e-01
seasons_Autumn	-3.345477e-01	-3.296859e-01	5.154560e-01
seasons_Spring	-3.369963e-01	-3.320989e-01	5.243712e-01
seasons_Summer	1.000000e+00	-3.320989e-01	-1.775682e-01
seasons_Winter	-3.320989e-01	1.000000e+00	-8.667263e-01
cluster	-1.775682e-01	-8.667263e-01	1.000000e+00

En la siguiente gráfica nos sirve para saber acerca de varios datos importantes entre ellos se encuentran la asimetría que en esta ocasión resulto siendo positiva, luego tenemos la curtosis cuyo es positivo y además cercano a 0 aquí sabemos que estos valores no son erróneos debido a la gran cantidad de datos que se encuentran concentrados en la parte izquierda del gráfico y que después generan una caída gradual.

Por ultimo tenemos los valores de la media y de la mediana que tienen como propósito el mostrarnos visualmente que el valor de la simetría es correcto esto se debe a que la media es mayor que la mediana.

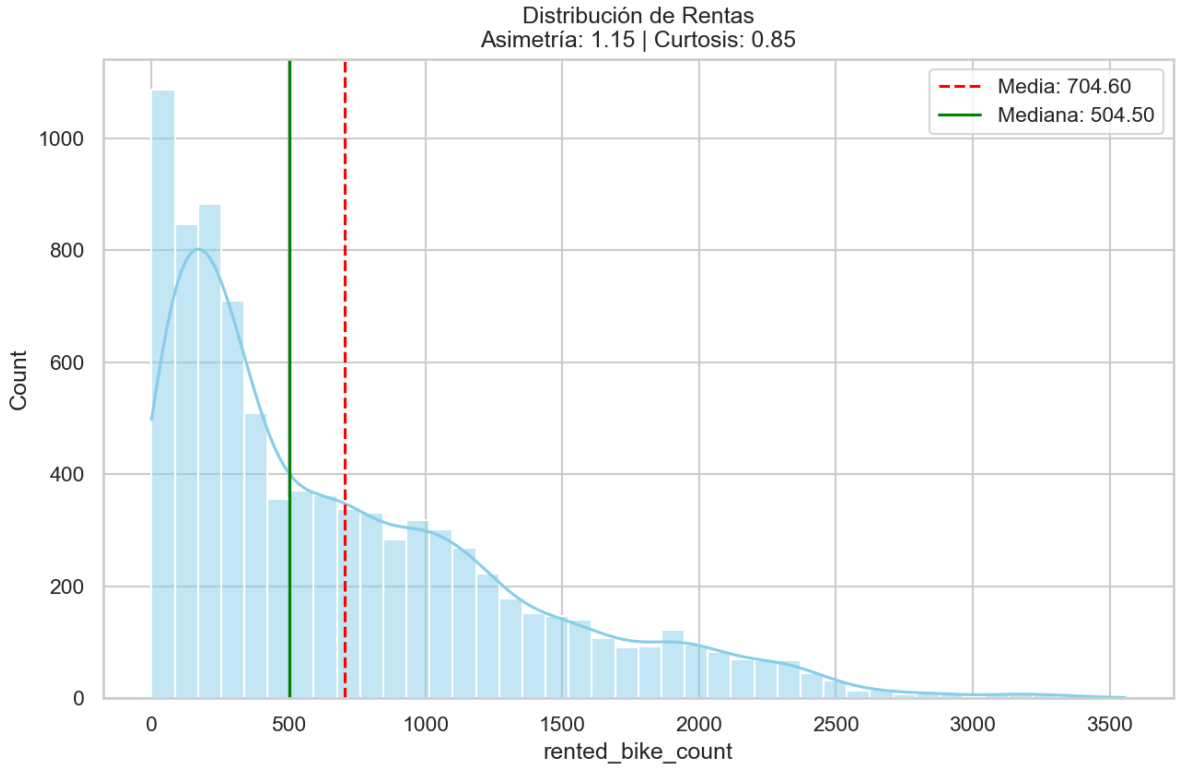

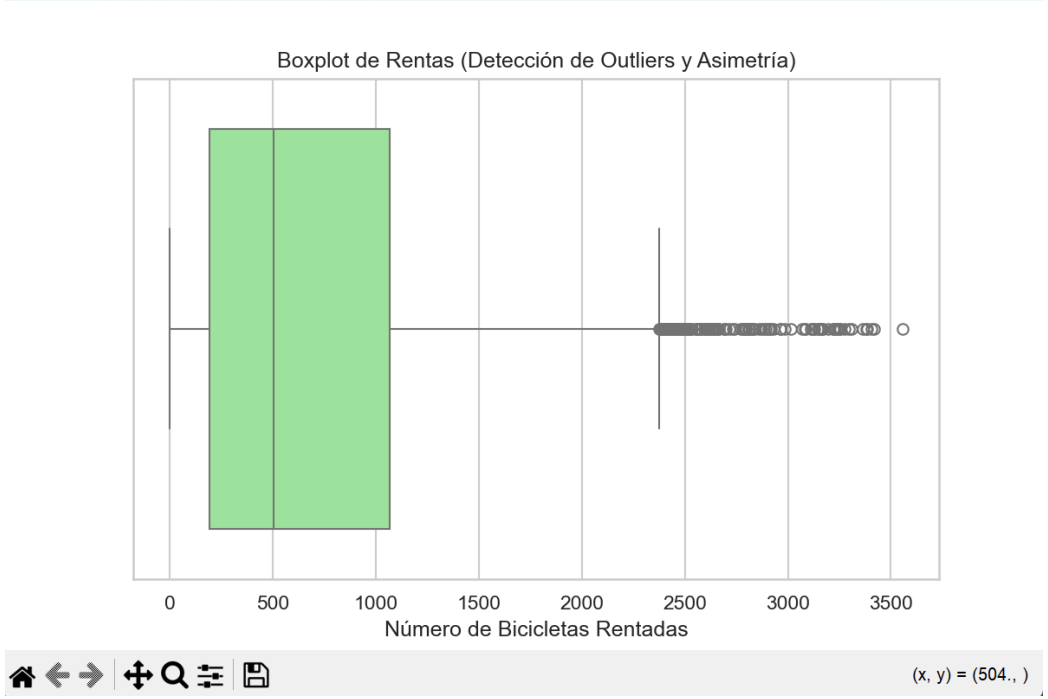

En esta gráfica hay tres puntos importantes los cuales hay que destacar el primero seria el rectángulo color verde que se encuentra en la parte izquierda del boxplot el cual representa el 50% central de la información, la línea izquierda de la caja indica que el 25 de horas registradas tuvo rentas muy bajas (alrededor de 200), la línea central representa la mediana la cual se muestra en la esquina inferior derecha de la captura lo que quiere decir que la mitad del tiempo se rento una cantidad inferior a 504 bicicletas y la otra mitad más de 504 bicicletas, por ultimo en el lado derecho se indica que el 75% de las horas tuvieron menos de 1000 unidades rentadas aproximadamente.

El segundo punto es acerca de las líneas verticales que se encuentran al inicio del gráfico y antes de los círculos, estas líneas representan lo que se conoce como comportamiento normal, es decir, cualquier valor que se encuentra después de este rango se considera como un comportamiento que no es típico.

Como ultimo punto están los círculos de la parte derecha los cuales representan los valores atípicos, es decir, las ocasiones en que las rentas superaron lo que se considero como valor normal o típico.