Gustavo Arreola Almaguer
2074164

Practica 6

Minería de Datos

K-Nearest Neighbors (KNN)

En esta sexta practica se utilizo la técnica de aprendizaje supervisado conocida como K-Nearest Neighbors la cual se utiliza comúnmente en problemas de clasificación aunque también puede aplicarse a problemas de regresión. Esta funciona al calcular alguna distancia como por ejemplo la euclidiana o la manhattan de un nuevo punto a los datos de entrenamiento, seleccionando los ‘k’ más cercanos y asignando la clase mayoritaria o el promedio.

Esta técnica clasifica los datos en función de su similitud con datos cercanos, utiliza métricas de distancia como la distancia euclidiana o manhattan las cuales se mencionaron anteriormente para encontrar los vecinos más cercanos.

Algo importante a mencionar es que KNN no hace suposiciones sobre la distribución de datos subyacente sino que se convierte en un método de aprendizaje no paramétrico y basado en instancias.

A este algoritmo también se le conoce como un algoritmo de aprendizaje perezoso porque no aprende de todo el conjunto de inmediato, sino que almacena todo este conjunto de datos y realiza los cálculos correspondiente solo al momento de la clasificación

Existen varios métodos que sirven para seleccionar el valor de k como la validación cruzada o el método de valores impares para k, pero en este caso preferí usar una tercera técnica conocida como elbow method o método del codo.

En este método se dibuja una gráfica que muestra una tasa de error o la precisión de diferentes valores de k. A medida que aumenta k el error suele disminuir inicialmente. Sin embargo, a partir de cierto punto, el error deja de disminuir rápidamente. El punto donde la curva cambia de dirección y adquiere forma de codo suele ser el valor óptimo para k.

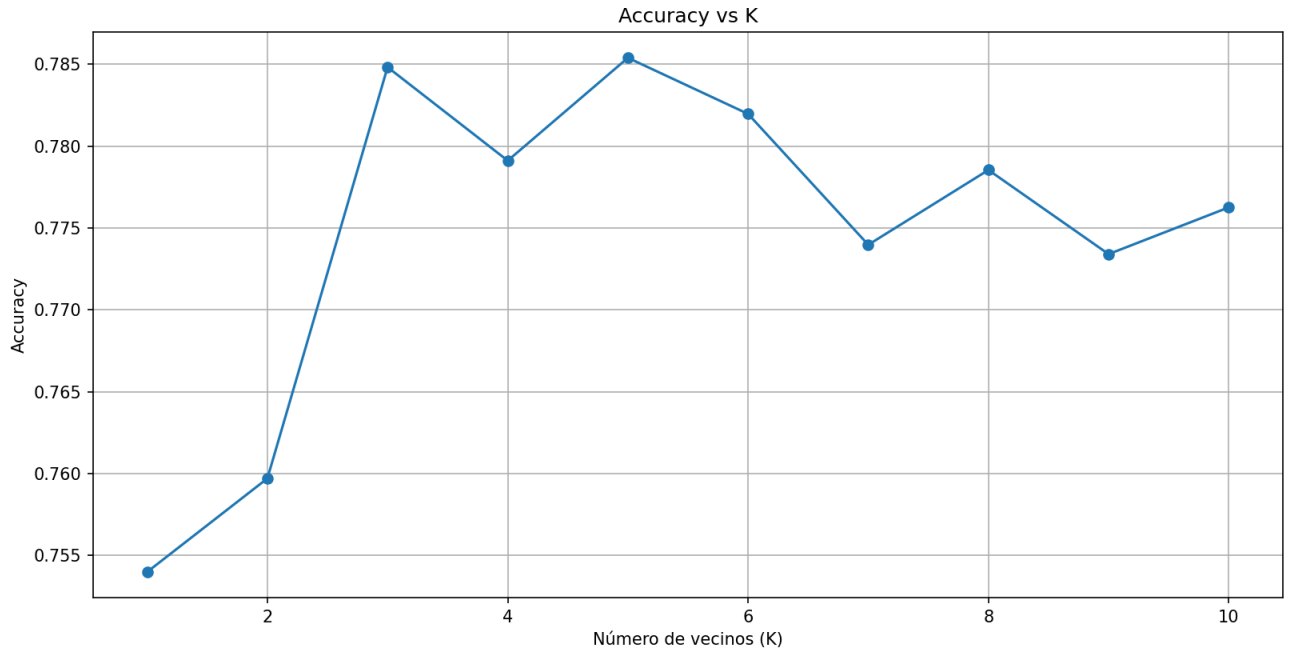


```
Mejor K: 5
Accuracy: 0.7854
```
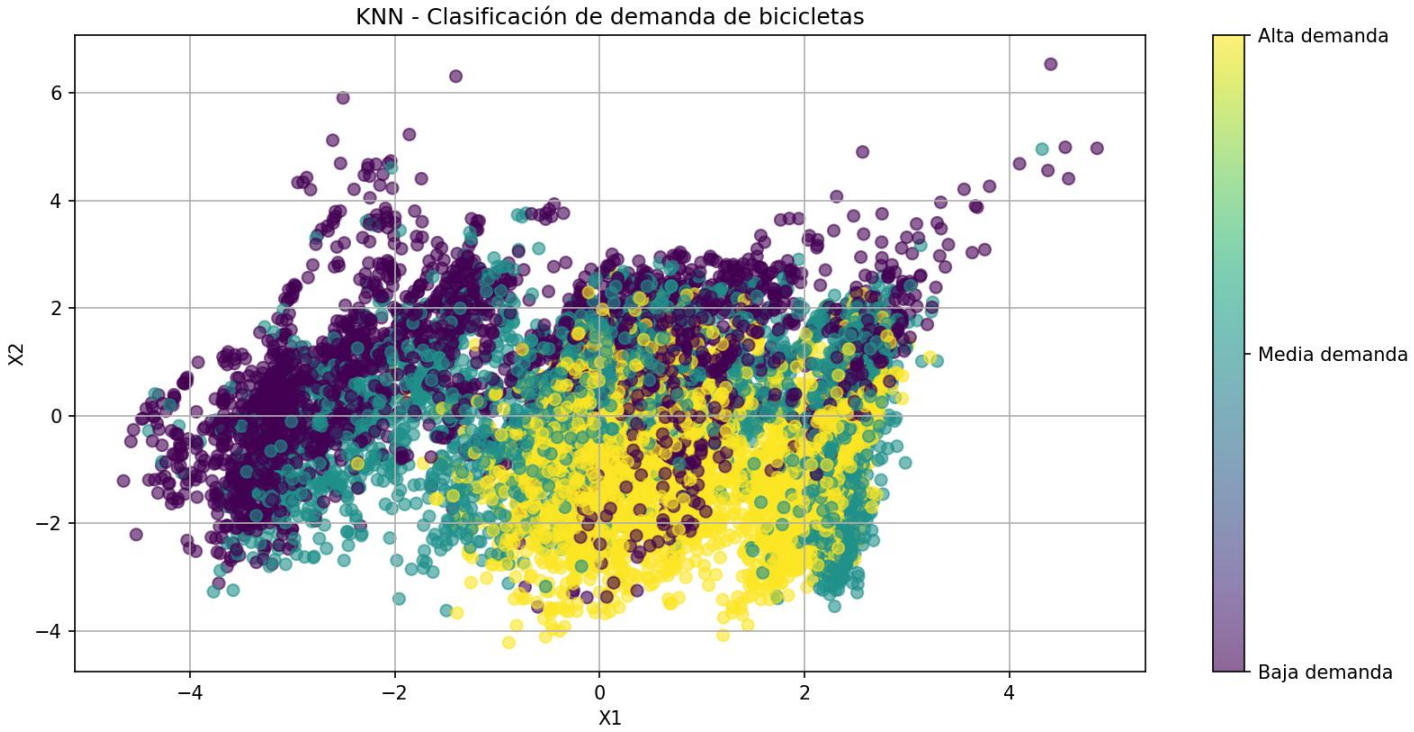
Para finalizar se realiza una gráfica que representa la clasificación de demanda de bicicletas la cual esta dividida en 3 categorías baja demanda, media demanda y alta demanda las cuales se encuentran representadas por varios colores cuya diferencia se puede apreciar por medio de una barra de colores la cual quiere decir que mientras más cerca del color morado más baja será la demanda de esa hora del año y mientras más cerca este del amarillo más alta será la demanda que se tuvo en esa hora.