Gustavo Arreola Almaguer
2074164

Practica 7

Minería de Datos

KMeans

En esta séptima practica se llevo a cabo la técnica de clustering conocida como KMeans para dividir nuestro dataset en varios grupos diferentes, donde las observaciones de cada grupo sean bastante similares entre si y muy diferentes a los otros grupos.

La cantidad de grupos escogidos para aplicar la técnica se baso en los resultados obtenidos del puntaje de silueta (Silhouette Score) seguido de una gráfica donde se aplicó el método del codo (Elbow Method).

Una vez que la cantidad de grupos fue escogida se creo una gráfica donde se plasman visualmente los resultados de la técnica de Kmeans utilizando el método de visualización PCA.

En el resto de la presentación se verán capturas del proceso, las cuales incluyen una explicación más detallada de las técnicas y de los métodos mencionados anteriormente

Puntaje de Silueta para varias cantidades de grupos

El puntaje de silueta es la distancia entre una muestra y el cluster más cercano del que la muestra no forma parte.

En el puntaje de silueta el mejor valor posible es 1 mientras que el peor valor es -1. Cuando los valores son cercanos a 0 estos indican clusters superpuestos. Los valores negativos generalmente indican que una muestra se ha asignado al cluster incorrecto ya que otro cluster es más similar.

Con esta técnica podemos averiguar cual es numero optimo de grupos para el dataset buscando el valor que maximice el coeficiente de silueta promedio. Siendo en este caso que la cantidad de grupos optima es de 4 grupos ya que cuenta con el puntaje de silueta más alto de los 9 grupos que se probaron.

```
Para k=2, el Silhouette Score es: 0.3480
Para k=3, el Silhouette Score es: 0.3264
Para k=4, el Silhouette Score es: 0.3596
Para k=5, el Silhouette Score es: 0.3108
Para k=6, el Silhouette Score es: 0.3068
Para k=7, el Silhouette Score es: 0.2858
Para k=8, el Silhouette Score es: 0.2840
Para k=9, el Silhouette Score es: 0.2812
Para k=10, el Silhouette Score es: 0.2838
```

Método del codo

Para verificar que la cantidad de grupos optima realmente sea la mostrada con los puntajes de silueta se realizo nuevamente la técnica conocida como método del codo (elbow method) donde podemos notar que aquí se muestra que 3 grupos es el numero más indicado para el dataset contradiciendo lo que dice el puntaje de silueta.

Para la ultima gráfica decidí basarme más en lo que dice el puntaje de silueta ya que el numero de grupos que alcance el puntaje máximo es el de 4. Esto debido a que al dividir en 4 grupos diferentes reduzco la ambigüedad entre las observaciones, lo que nos da una segmentación más concreta de las condiciones climáticas y de la demanda.

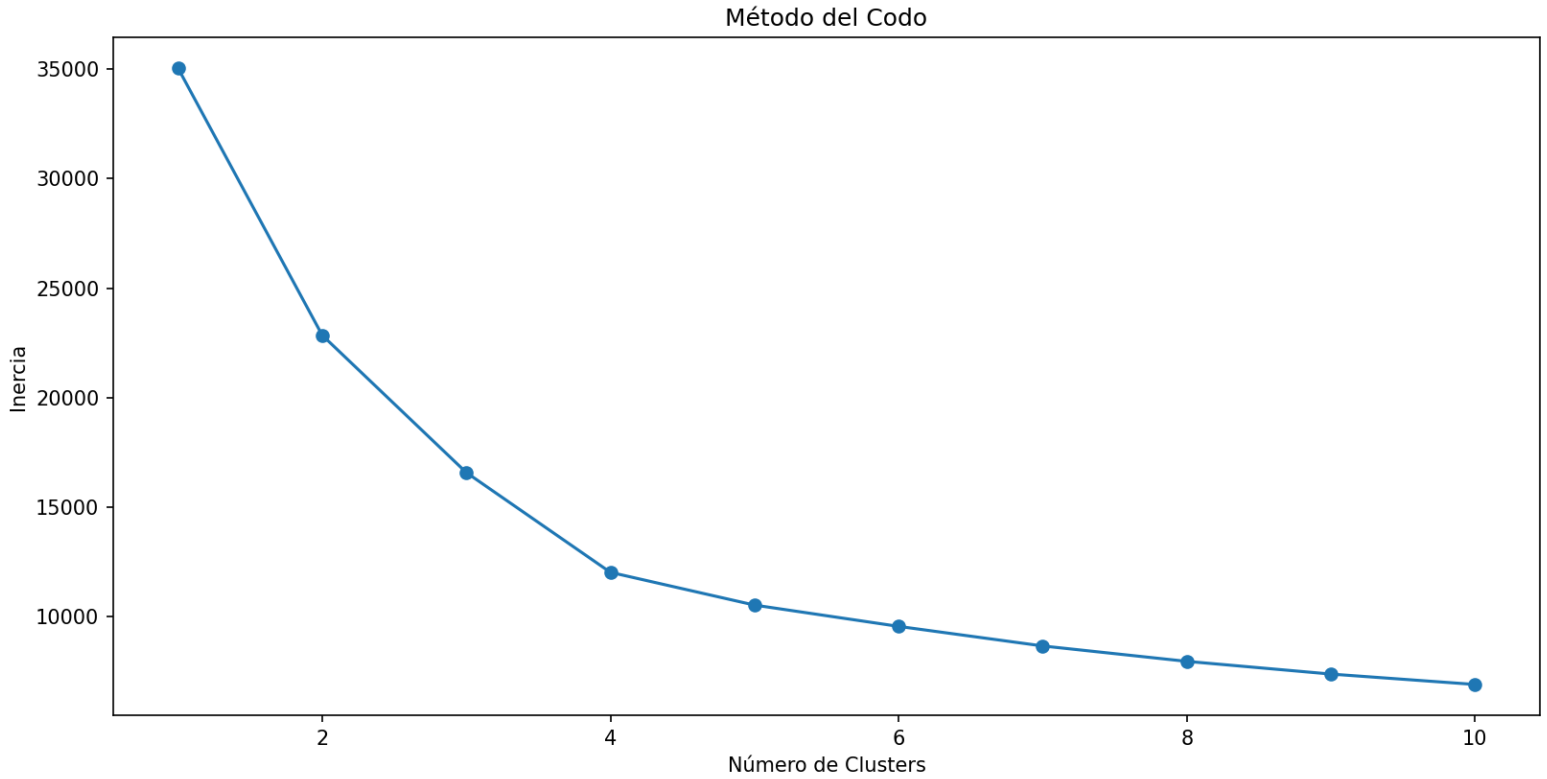

Visualización de Clusters

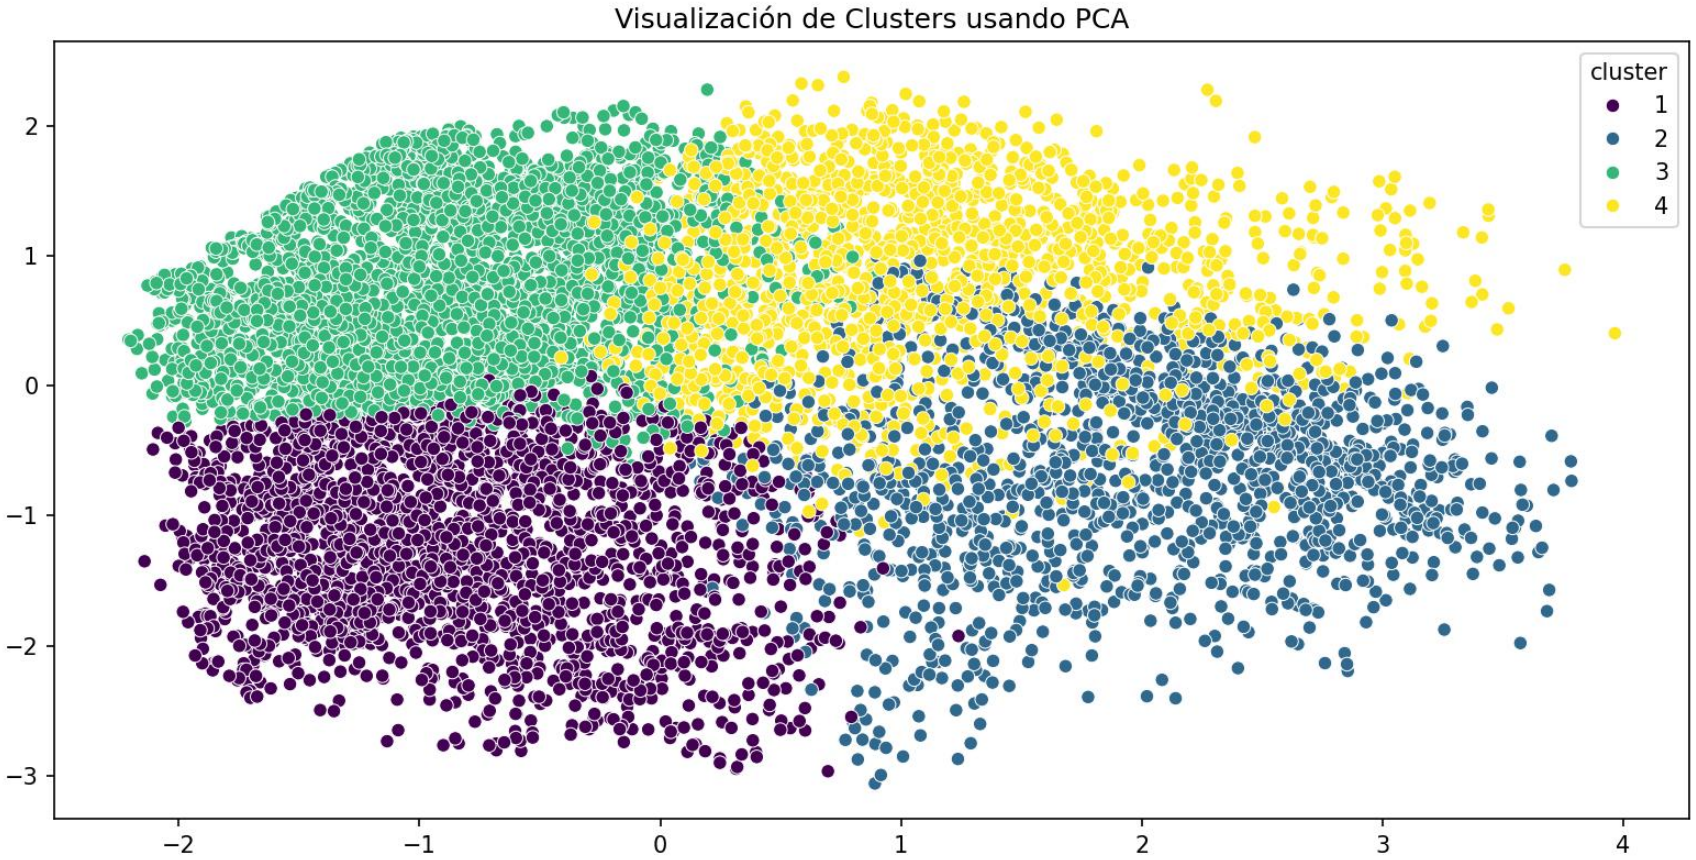

Cada uno de los colores presentes representa diferentes condiciones climatológicas y rendimiento de rentas, por ejemplo el cluster 1 quiere decir que hubo una demanda baja al igual que temperaturas bajas, por otro lado el cluster 2 representa que hubo una demanda moderada además de que el clima fue nublado o fresco, el cluster 3 también tiene su propia distinción la cual es que hubo un flujo constante de usuarios y se conto con un clima agradable y para finalizar tenemos el cluster 4 que representa el punto más alto de demanda al igual que representa el punto más alto de radiación solar.